

Universidade do Minho
Escola de Engenharia
Licenciatura em Engenharia Informática

Aprendizagem e Decisão Inteligentes

Ano Letivo de 2025/2026

Conceção de modelos de aprendizagem e decisão

Grupo 50

João Teixeira
A106836

Simão Mendes
A106928

Tomás Machado
A104186

April 29, 2026

ADI

Índice

1. Introdução	1
2. <i>DataSet</i> Par	2
2.1. Introdução, Pré-Processamento e Exploração do Domínio	2
2.2. Limpeza de Dados e Processamento Básico	8
2.3. Desenvolvimento de Modelos e Análise de Resultados	10
2.3.1. Modelação e Avaliação: Classificação	10
2.3.2. Modelação e Avaliação: Regressão	14
2.4. Balanço Crítico e Conclusões Técnicas	16
3. <i>DataSet</i> Grupo	18
3.1. Introdução, Pré-Processamento e Exploração do Domínio	18
3.2. Visualização Gráfica e Análise Exploratória	19
3.3. Tratamento de Dados	23
3.4. Modelação e Avaliação	25
3.5. Balanço Crítico e Conclusões Técnicas	28
4. Conclusão	30
5. Referências Bibliográficas	31

Lista de Figuras

Figura 1	Metanó de Ingestão de Dados e Limpeza Preliminar (<i>DataSet</i> Produção). . .	3
Figura 2	Matriz de correlações lineares entre atributos numéricos (<i>DataSet</i> Produção).	5
Figura 3	Evolução temporal das métricas com eixos normalizados (<i>DataSet</i> Produção).	5
Figura 4	Dispersão entre a radiação solar direta e a produção fotovoltaica (<i>DataSet</i> Produção).	6
Figura 5	Comparação de fontes de energia e distribuição de classes (<i>DataSet</i> Produção).	7
Figura 6	Identificação de valores extremos na produção energética por mês (<i>DataSet</i> Produção).	7
Figura 7	Fluxo interno do metanó <i>Data Cleaning & Base Processing</i> (<i>DataSet</i> Produção).	8
Figura 8	Fluxo de modelação e avaliação para classificação (<i>DataSet</i> Produção). . . .	11
Figura 9	Fluxo de modelação e avaliação para regressão (<i>DataSet</i> Produção).	14
Figura 10	Distribuição de preços por fabricante.	19
Figura 11	<i>HeatMap</i> entre atributos numéricos e preço.	20
Figura 12	Distribuição de frequência dos preços dos portáteis.	21
Figura 13	Composição percentual das categorias de portáteis (<i>TypeName</i>).	22
Figura 14	Dispersão da memória RAM em função do preço de venda.	23
Figura 15	Fluxo global de tratamento, modelação e avaliação.	23
Figura 16	Fluxo <i>Regression Tree + Opt.</i>	25
Figura 17	Fluxo <i>Random Forest + Opt.</i>	26
Figura 18	Fluxo <i>GBT Regression + Opt.</i>	26
Figura 19	Fluxo Rede Neural Keras.	27
Figura 20	Fluxo <i>Ensemble RF + GBT.</i>	27

Lista de Tabelas

Tabela 1	Dicionário de atributos do conjunto de dados (<i>DataSet</i> Produção).	2
Tabela 2	Exemplo da técnica <i>One-Hot Encoding</i> aplicada às direções cardeais (<i>DataSet</i> Produção).	9
Tabela 3	Impacto do pré-processamento na precisão do modelo (<i>DataSet</i> Produção).	12
Tabela 4	Otimização de hiperparâmetros do algoritmo GBT (<i>DataSet</i> Produção). . .	12
Tabela 5	Desempenho final dos modelos de classificação (<i>DataSet</i> Produção).	13
Tabela 6	Métricas por classe do modelo GBT (<i>DataSet</i> Produção).	13
Tabela 7	Matriz de confusão do modelo GBT (<i>DataSet</i> Produção).	14
Tabela 8	Otimização de hiperparâmetros dos modelos de regressão (<i>DataSet</i> Produção).	15
Tabela 9	Validação de robustez do modelo de regressão GBT (<i>DataSet</i> Produção). .	15
Tabela 10	Dicionário de atributos do conjunto de dados (<i>DataSet Laptop Prices</i>). . . .	18

1. Introdução

O presente relatório detalha o desenvolvimento do projeto prático realizado no âmbito da unidade curricular de Aprendizagem e Decisão Inteligentes. O objetivo central desta tarefa incidiu na aplicação de conhecimentos teóricos e práticos sobre sistemas de Machine Learning na resolução de dois problemas distintos: um orientado para a análise de produção energética (*DataSet Par*) e outro focado na análise do mercado de computadores portáteis (*DataSet Grupo*).

O trabalho visou aplicar técnicas de extração de conhecimento a partir de dados, com a passagem pelas fases centrais requeridas para a conceção de modelos preditivos.

A Abordagem CRISP-DM no Contexto Académico: A condução do projeto estruturou-se na base da metodologia CRISP-DM (*Cross-Industry Standard Process for Data Mining*). Contudo, dada a natureza estritamente académica deste trabalho, o ciclo de desenvolvimento tradicional sofreu uma adaptação. As fases de **Compreensão do Negócio (Business Understanding)** e de **Implementação (Deployment)** não foram executadas, uma vez que a sua aplicabilidade escapa ao âmbito laboratorial e aos requisitos da unidade curricular. Desta forma, a análise de cada um dos problemas concentrou-se exclusivamente nas restantes quatro etapas técnicas:

- **Compreensão dos Dados:** Exploração inicial e análise estatística de atributos.
- **Preparação dos Dados:** Limpeza de anomalias, tratamento de valores omissos e transformação matemática (*feature engineering*).
- **Modelação:** Seleção, parametrização e treino de algoritmos de aprendizagem.
- **Avaliação:** Análise crítica do desempenho dos modelos com base em métricas estatísticas adequadas.

Este documento encontra-se organizado em dois capítulos principais, correspondentes ao *DataSet Par* e ao *DataSet Grupo*. Ambos os capítulos seguem a estrutura metodológica descrita, permitindo uma análise comparativa e sistemática do fluxo de trabalho e dos resultados obtidos em cada domínio. O relatório encerra com as conclusões decorrentes do processo analítico global.

2. *DataSet Par*

Este capítulo descreve a abordagem metodológica aplicada à análise e modelação preditiva do ***DataSet Par***. O fluxo analítico avança desde a exploração e limpeza estrutural dos dados até ao treino e avaliação de algoritmos de ***Machine Learning***. O objetivo central consiste em antecipar a resposta do setor energético face a cenários meteorológicos, dividindo-se o problema em duas abordagens preditivas distintas: a classificação do nível de produção e a regressão da carga total produzida pela rede.

2.1. Introdução, Pré-Processamento e Exploração do Domínio

O conjunto de dados em estudo reflete a interação direta entre a meteorologia e o setor energético. A sua estrutura resulta da integração de registos operacionais de redes de distribuição (produção térmica, hídrica, eólica e fotovoltaica) com dados climáticos de superfície (temperatura, radiação solar, precipitação e comportamento do vento). Este cruzamento de informações possibilita a modelação e a antecipação da carga exigida à rede com base nas condições atmosféricas. Para contextualizar a informação base, a Tabela 1 apresenta a descrição detalhada de todos os atributos presentes no conjunto de dados original.

Atributo	Tipo	Descrição
RowID	ID	Identificação unívoca da linha de registo.
Date/Time	Temporal	Data e hora da observação.
Cogeneration (kWh)	Numérico	Produção em unidades de cogeração.
Wind (kWh)	Numérico	Produção de origem eólica.
Photovoltaics (kWh)	Numérico	Produção de origem fotovoltaica.
Hydro (kWh)	Numérico	Produção de origem hídrica.
Other Technologies (kWh)	Numérico	Produção noutras tecnologias.
Distribution Network (kWh)	Numérico	Produção total na rede de distribuição (Alvo - Regressão).
temperature_2m (°C)	Numérico	Temperatura exterior a 2 metros de altura.
relative_humidity_2m (%)	Numérico	Percentagem de humidade relativa exterior.
precipitation (mm)	Numérico	Precipitação total registada.
rain (mm)	Numérico	Queda de chuva.
snowfall (cm)	Numérico	Queda de neve.

cloud_cover (%)	Numérico	Percentagem de cobertura de nuvens.
Wind_Direction_10m	Categórico	Direção qualitativa do vento a 10 metros.
wind_speed_10m (km/h)	Numérico	Velocidade do vento a 10 metros.
Wind_Direction_100m	Categórico	Direção qualitativa do vento a 100 metros.
wind_speed_100m (km/h)	Numérico	Velocidade do vento a 100 metros.
direct_radiation (W/m ²)	Numérico	Radiação solar direta.
shortwave_radiation (W/m ²)	Numérico	Radiação solar de onda curta.
diffuse_radiation (W/m ²)	Numérico	Radiação solar difusa.
direct_normal_irradiance (W/m ²)	Numérico	Irradiância solar normal direta.
terrestrial_radiation (W/m ²)	Numérico	Radiação emitida pela superfície terrestre.
Productions	Categórico	Classe de taxa de produção (Alvo - Classificação).

Tabela 1: Dicionário de atributos do conjunto de dados (*DataSet* Produção).

O processo analítico iniciou-se com a ingestão e limpeza preliminar. A importação efetuou-se através do nó **CSV Reader**, configurado especificamente para interpretar o delimitador de separação correto (ponto e vírgula) e assegurar a leitura íntegra do ficheiro. Seguiu-se a exclusão de atributos redundantes, nomeadamente as colunas RowID e rain (mm), através do nó **Column Filter**. Em sequência, o recurso a três nós **String Replacer** serviu o propósito de remover o texto literal nan dos registos de cogeração, produção fotovoltaica e radiação difusa. Esta limpeza textual viabilizou a aplicação do nó **String to Number**, o qual forçou a tipagem correta destas variáveis para formato numérico decimal, e a fase concluiu-se com o **Number Rounder** para uniformizar a precisão algorítmica.




Figura 1: Metanó de Ingestão de Dados e Limpeza Preliminar (*DataSet* Produção).

A exploração inicial decorreu num metanó dedicado, com um pré-processamento focado estritamente na representação visual. A conversão temporal (**String to Date&Time** e **Date&Time Part Extractor**) viabilizou a agregação diária de dados via **GroupBy**. Em

paralelo, o nó **Unpivot** reestruturou a tabela para simplificar a criação de gráficos multivariáveis. Para uniformizar os eixos e evitar enviesamentos visuais, o **Normalizer** (Min-Max entre 0 e 1) padronizou grandezas dispares (como radiação e temperatura), enquanto o nó **Missing Value** substituiu eventuais omissões pela constante zero (0.0), de modo a assegurar a continuidade geométrica ininterrupta de linhas e barras nos gráficos.

A análise descritiva baseou-se na observação dos seguintes elementos visuais gerados no fluxo de trabalho:

- **Qualidade dos Dados e Estatística (*Statistics*):** A inspeção estatística dividiu-se em duas vertentes. No separador nominal, confirmou-se a presença de valores omissos em atributos categóricos, por exemplo nas colunas `Wind_Direction_10m`, `precipitation (mm)` e `cloud_cover (%)`. Por sua vez, a análise do separador numérico focou-se nas métricas de distribuição, onde se verificou que atributos como a precipitação possuem uma distribuição fortemente assimétrica com concentração massiva no zero.
- **Matriz de Correlações (*Linear Correlation*):** O cálculo das dependências lineares evidenciou associações relevantes para as fases subsequentes. Constatou-se uma correlação forte e positiva entre a radiação solar direta (`direct_radiation`) e a produção fotovoltaica (`Photovoltaics (kWh)`), tal como entre a velocidade do vento a 100 metros (`wind_speed_100m`) e a respetiva produção eólica (`Wind (kWh)`). Em contrapartida, o atributo de precipitação (`precipitation (mm)`) apresentou um impacto quase nulo sobre a carga total da rede, ao passo que a humidade relativa revelou uma relação inversa com os índices de radiação.




Figura 2: Matriz de correlações lineares entre atributos numéricos (*DataSet Produção*).

- **Evolução e Sazonalidade (*Line Plot*):** A representação sequencial dos registos confirmou a existência de padrões temporais. Os gráficos com eixos normalizados demonstram que a produção energética sofre oscilações severas que dependem da sazonalidade e de fatores meteorológicos diretos. Destaca-se a forte sincronia diária entre os picos de radiação solar e de irradiância, a elevação da temperatura e a correspondente maximização da produção fotovoltaica.




Figura 3: Evolução temporal das métricas com eixos normalizados (*DataSet Produção*).

- **Relações entre Variáveis (*Scatter Plot*):** A análise de dispersão corroborou as tendências da matriz matemática. A disposição geométrica dos pontos ilustra de forma clara a forte relação de dependência entre a velocidade do vento a 100 metros e a produção de energia eólica. Observa-se que o aumento da intensidade do vento resulta num crescimento acentuado da energia gerada, descrevendo o perfil de produção característico dos aerogeradores.




Figura 4: Dispersão entre a radiação solar direta e a produção fotovoltaica (*DataSet Produção*).

- **Distribuição de Fontes e Classes Alvo (*Pie Chart e Bar Chart*):** A análise comparativa das fontes de energia revela que a produção eólica é o componente dominante, sendo responsável por mais de 50% do total da energia gerada. No que concerne à variável alvo de classificação (*Productions*), a distribuição das instâncias concentra-se maioritariamente nas categorias **Medium-Low** e **High**.

Esta fase de exploração permitiu detetar falhas críticas na qualidade dos dados categóricos. Identificaram-se entradas redundantes e inconsistentes, com a coexistência de termos em idiomas distintos (Português e Inglês) e o uso de abreviaturas para designar a mesma classe. Esta constatação justifica a aplicação posterior de uma limpeza profunda e a normalização dos domínios nominais para garantir a coesão do modelo.




Figura 5: Comparação de fontes de energia e distribuição de classes (*DataSet Produção*).

- **Deteção de Anomalias (Box Plot):** Os diagramas de extremos e quartis expuseram a existência de *outliers* significativos em colunas de produção, nomeadamente em Photovoltaics (kWh) e Hydro (kWh). A análise mensal revela a ocorrência frequente de valores atípicos, o que sugere a existência de dias com condições meteorológicas excepcionais para a época, como picos de radiação no inverno ou pluviosidade intensa fora do período expectável. Por se tratarem de eventos reais e naturais, esta observação vetou a remoção pura das linhas e justificou o recurso futuro a técnicas estatísticas de contenção de limites (*Capping*), de forma a estabilizar a aprendizagem do modelo sem perder informação histórica relevante.




Figura 6: Identificação de valores extremos na produção energética por mês (*DataSet Produção*).

2.2. Limpeza de Dados e Processamento Básico

A fase de preparação de dados assume um papel central no ciclo de vida de qualquer projeto de **Machine Learning**. Após a identificação de anomalias, redundâncias e valores omissos na fase exploratória, torna-se imperativo aplicar um conjunto de transformações matemáticas e lógicas para garantir que os algoritmos de treino recebem uma matriz de dados íntegra, coerente e puramente numérica. Todo este processo de transformação e limpeza encontra-se encapsulado no metanó **Data Cleaning & Base Processing**, cuja arquitetura sequencial ilustra a metodologia de pré-processamento adotada.




Figura 7: Fluxo interno do metanó *Data Cleaning & Base Processing* (DataSet Produção).

O fluxo desenhado na Figura 7 opera de forma estritamente sequencial. Cada nó cumpre um propósito específico de transformação, de redução de ruído ou de validação física dos atributos originais. A seguir, detalha-se a função e a justificação teórica de cada passo implementado, com o objetivo de assegurar total transparência analítica.

Conversão Temporal e Limpeza Estrutural: O processamento arranca com a transformação da coluna temporal através do nó **String to Date&Time**. Os dados originais apresentam a variável Date/Time num formato de texto simples. Para que o sistema consiga interpretar a cronologia dos eventos com rigor, este nó força a conversão do texto para um objeto temporal nativo.

Com a cronologia assegurada, o fluxo avança para o primeiro nó **Missing Value**. Este atua como um filtro de integridade estrito, focado na eliminação cirúrgica de seis entradas anómalas originadas por erros de conversão de datas no sistema original (como a existência de um dia fictício “2025-11-32”). A remoção destas linhas isoladas assegura a coesão temporal sem comprometer o volume de dados. Logo após, o nó **Column Filter** procede à exclusão da coluna original de data completa, dado que o seu formato integral representa ruído. Para preservar a inteligência cíclica, o nó **Date&Time Part Extractor** assume a função de fragmentar a cronologia em atributos numéricos independentes, extraíndo a hora do dia, o dia e o mês, o que ensina aos modelos conceitos vitais como o “pico de consumo diário”.

Normalização de Classes e Validação Física: A robustez do pré-processamento consolida-se com a aplicação de uma bateria de nós **Rule Engine**. O primeiro dedica-se a harmonizar a variável de classificação (Productions). A exploração detetou uma fragmentação grave das classes devido a traduções e abreviaturas. Este nó aplica lógicas condicionais para unificar as categorias no padrão em inglês (consolidando termos como “Alto” ou “Hgh” na classe “High”, “MedioBaixo” e “MedLow” em “Medium-Low”, “Baixo” e “Lw” em “Low”, entre outros).

Os dois nós **Rule Engine** seguintes introduzem leis do mundo físico para auditar os sensores de produção. O segundo nó valida a produção fotovoltaica, forçando o registo a zero em períodos de escuridão (horas anteriores às 06:00 e posteriores às 20:00) ou quando a radiação solar direta é nula. O terceiro nó condiciona a produção eólica à existência de vento, impondo o valor zero sempre que os anemómetros a 10 e 100 metros de altitude não detetam qualquer velocidade de fluxo de ar.

Tratamento de Valores Omissos e Auditoria da Rede: Para colmatar as omissões na restante base de dados, o segundo nó **Missing Value** implementa estratégias diferenciadas. Para eventos discretos (precipitação, queda de neve) e produções baseadas em ativação (cogeração, outras tecnologias), fixa-se o valor constante em zero. Esta decisão baseia-se na premissa lógica de que a falha de registo nestes parâmetros significa a ausência do fenómeno (por exemplo, um valor omissos na precipitação indica que não choveu). Para os restantes atributos meteorológicos contínuos, aplica-se o cálculo da mediana, uma escolha matemática justificada por ter demonstrado os melhores resultados empíricos de estabilidade durante os testes de modelação. Já a correção das direções do vento a 10 e 100 metros recorre à técnica do valor prévio (*Previous Value*), o que respeita a continuidade natural das correntes de ar.

A viabilidade da regressão exige a exatidão da carga total injetada na rede (Distribution Network). Para o garantir, um nó **Math Formula** apura uma nova variável com o somatório rigoroso de todas as fontes de energia (Cogeração, Eólica, Fotovoltaica, Hídrica e Outras). O quarto **Rule Engine** utiliza esta soma como termo de validação: sempre que a carga da rede se encontra ausente, regista valores negativos ou diverge do somatório real, o sistema sobrepõe automaticamente o valor da soma calculada, assegurando total harmonia termodinâmica.

Binarização e Otimização de Dimensionalidade: A fase final do metanó adapta a informação à exigência dos modelos de aprendizagem automática, os quais requerem matrizes de dados puramente numéricas. A conversão das direções nominais do vento para números sequenciais induziria os algoritmos a assumir falsas relações de grandeza. A técnica de **One-Hot Encoding**, executada pelo nó **One to Many**, resolve este obstáculo ao separar as direções a 10 e 100 metros em colunas binárias independentes, onde o valor 1 representa a presença e o valor 0 a ausência, conforme demonstrado na Tabela 2.

Categoria Original	Wind_North	Wind_South	Wind_East	Wind_West
North	1	0	0	0
South	0	1	0	0
East	0	0	1	0
West	0	0	0	1

Tabela 2: Exemplo da técnica *One-Hot Encoding* aplicada às direções cardeais (*DataSet* Produção).

O metanó conclui a sua operação com a aplicação de um último nó ***Column Filter***. Este filtro executa a limpeza estrutural final da base de dados, através da remoção das variáveis originais de direção do vento (em formato de texto) e da variável temporária do somatório global, cuja utilidade de validação terminou. Embora qualquer conjunto de dados reais retenha inevitavelmente algum grau de ruído e imperfeição, esta fase de pré-processamento devolve uma matriz substancialmente mais consistente, com dimensionalidade controlada e estruturada para conferir maior estabilidade matemática às futuras fases de treino dos modelos de previsão.

2.3. Desenvolvimento de Modelos e Análise de Resultados

Concluída a preparação base dos dados, o trabalho avançou para a fase de modelação e avaliação. Para garantir uma análise estruturada, o processo foi dividido segundo a natureza dos problemas preditivos: a classificação das categorias de produção e a regressão da carga total produzida. Em ambos os casos, aplicaram-se técnicas de processamento avançado, seguidas pelo treino de algoritmos e pela aferição rigorosa do seu desempenho.

2.3.1. Modelação e Avaliação: Classificação

O desenvolvimento do modelo de classificação exigiu uma arquitetura de processamento avançado, desenhada não apenas para treinar algoritmos, mas para os submeter a um escrutínio metodológico rigoroso. O fluxo de trabalho ilustrado na Figura 8 engloba a estabilização matemática da matriz, análises de sensibilidade ao pré-processamento, estratégias de particionamento e a otimização de hiperparâmetros para três arquiteturas distintas: ***Decision Tree***, ***Random Forest*** e ***Gradient Boosted Trees***.




Figura 8: Fluxo de modelação e avaliação para classificação (*DataSet* Produção).

Prevenção de Fuga de Informação e Estabilização Numérica: A vertente de classificação inicia a sua operação através de um nó **Column Filter**, configurado para isolar a variável alvo categórica (Productions). Esta etapa remove a variável numérica Distribution Network (kWh), de forma a impedir que o modelo memorize a resposta correta através de uma correlação matemática direta com a carga total, um fenómeno conhecido como fuga de informação (**Data Leakage**).

Antes da submissão dos dados aos algoritmos preditivos, o fluxo estabeleceu uma linha de base experimental para o tratamento de imperfeições. Para as anomalias, configurou-se o nó **Numeric Outliers** com a estratégia de contenção (**Capping**), com limites ditados pelas barreiras interquartis. Em paralelo, o nó **Normalizer** introduziu a padronização **Z-Score**, a qual transforma a distribuição de cada variável numérica para uma média nula e um desvio padrão unitário. Embora estas técnicas assumam um papel crítico em algoritmos sensíveis à variância, a sua real eficácia nas arquiteturas de árvores exigiu uma validação empírica.

Análise de Sensibilidade e Combinações de Pré-Processamento: Para atestar se as decisões de limpeza de dados maximizam a precisão, o projeto executou um estudo de impacto cruzado. A Tabela 3 ilustra como a combinação de diferentes técnicas de tratamento de valores omissos, anomalias e escalas influencia a **Accuracy** final (testada com a arquitetura **Gradient Boosted Trees**).

ID	Missing Values	Outliers	Normalizer	Accuracy (%)
1	Mediana	Nenhum	Nenhum	85,649
2	Média	Capping	Z-Score	85,137
3	Linear Interpolation	Capping	Z-Score	83,542
4	Average Interpolation	Capping	Z-Score	83,144
5	Mediana	Capping	Min-Max	85,478
6	Mediana	Capping	Z-Score	85,478
7	Mediana	Remoção	Z-Score	80,060

Tabela 3: Impacto do pré-processamento na precisão do modelo (*DataSet* Produção).

A análise empírica da Tabela 3 validou a decisão de excluir a ação dos nós **Normalizer** e **Numeric Outliers** do processamento final. O cenário com intervenção mínima (ID 1) atingiu a **Accuracy** máxima (85,649%). Este resultado indicia que a escala dos atributos é matematicamente irrelevante para a construção de árvores de decisão. Mais importante ainda, comprova que, no domínio energético, os valores estatisticamente extremos (**outliers**) representam fenómenos meteorológicos genuínos e de elevado valor preditivo (como picos de radiação ou rajadas de vento). A contenção (**Capping**) ou remoção (ID 7) destes eventos elimina capital de informação crucial, com impacto negativo no desempenho. O empate técnico entre **Z-Score** e **Min-Max** confirma também que o modelo opera com base em pontos de corte ordinais, uma vez que é imune à escala linear.

Otimização Computacional de Hiperparâmetros: A procura pelo limite de precisão incidu sobre o algoritmo **Gradient Boosted Trees**, submetido a um mecanismo iterativo (**Parameter Optimization Loop**). O estudo avaliou combinações da profundidade máxima das árvores (**Tree Depth**), do número total de modelos sucessivos (**Number of Models**) e da taxa de aprendizagem (**Learning Rate**). O **benchmark** da Tabela 4 detalha o desempenho e os parâmetros ótimos encontrados por cada estratégia de procura.

Método	Accuracy (%)	Tempo (min:s)	Iterações	Melhores Parâmetros (D, M, LR)
Brute Force	87,813	9:13	128	(9, 50, 0.2)
Random Search	87,016	0:44	10	(9, 81, 0.165)
Hill Climbing	87,073	0:40	11	(5, 161, 0.1)
Bayesian Opt.	87,130	2:17	25	(10, 152, 0.14)

Tabela 4: Otimização de hiperparâmetros do algoritmo GBT (*DataSet* Produção).

O processo de **Parameter Optimization** foi aplicado de forma equitativa às três arquiteturas em estudo. Contudo, este relatório detalha apenas os ciclos relativos ao **Gradient Boosted Trees**, uma vez que esta arquitetura superou de forma consistente o desempenho das restantes em todos os cenários de teste.

Estratégias de Validação e Comparação Final de Modelos: Concluída a otimização, o projeto avaliou a resiliência final dos algoritmos através de amostragem estratificada (**Stratified sampling**) com base na coluna *Productions*, de forma a assegurar a fide-

dade estatística entre os conjuntos de treino e teste. A Tabela 5 resume a comparação final entre o particionamento simples (**Hold-out** a 80/20) e a validação cruzada (**Cross-Validation**).

Algoritmo	Accuracy (Hold-out) (%)	Accuracy (Cross-Val) (%)
Decision Tree	86,162	84,562
Random Forest	85,763	84,494
Gradient Boosted Trees	87,813	86,214

Tabela 5: Desempenho final dos modelos de classificação (*DataSet* Produção).

O **Gradient Boosted Trees** consolidou-se como o modelo de referência, ao atingir a marca de 87,813% na sua configuração otimizada (**Tree Depth**: 9, **Number of Models**: 50, **Learning Rate**: 0.2). A sua superioridade deve-se à lógica sequencial de correção de erros residuais, que permite capturar padrões complexos que a **Decision Tree** e a **Random Forest** não conseguem isolar com a mesma precisão.

Análise Detalhada de Desempenho e Matriz de Confusão: Embora a **Accuracy** global ateste a eficácia geral do modelo, uma avaliação rigorosa exige a decomposição do erro por categoria. A Tabela 6 apresenta as métricas de Precisão (**Precision**), Revocação (**Recall**) e a sua média harmónica (**F-Measure**) para as diferentes classes no modelo **Gradient Boosted Trees**.

Classe de Produção	Precision	Recall (Sensitivity)	F-Measure
<i>High</i>	0,841	0,884	0,862
<i>Medium-High</i>	0,916	0,832	0,872
<i>Medium</i>	0,899	0,811	0,853
<i>Medium-Low</i>	0,894	0,927	0,910
<i>Low</i>	0,875	0,868	0,872

Tabela 6: Métricas por classe do modelo GBT (*DataSet* Produção).

A análise destas métricas demonstra um desempenho globalmente robusto e equilibrado, com a medida F (**F-Measure**) a superar a marca de 0,85 em todas as categorias. A classe **Medium-Low** destaca-se com a maior precisão combinada, enquanto a classe **Medium** exibe a maior dificuldade de identificação. Esta variação reflete a natural complexidade matemática na classificação de estados de transição atmosférica. Esta dinâmica torna-se evidente na Matriz de Confusão da Tabela 7, que mapeia as predições face aos valores reais.

Real / Previsto	<i>High</i>	<i>Med-High</i>	<i>Medium</i>	<i>Med-Low</i>	<i>Low</i>
<i>High</i>	427	3	0	21	32
<i>Medium-High</i>	26	218	4	4	10
<i>Medium</i>	3	5	133	22	1
<i>Medium-Low</i>	27	7	1	455	1
<i>Low</i>	25	5	10	7	309

Tabela 7: Matriz de confusão do modelo GBT (*DataSet* Produção).

A matriz evidencia que o algoritmo concentra a maioria das previsões corretas na diagonal principal. Todavia, registra-se a ocorrência de confusões severas pontuais entre classes diametralmente opostas (com destaque para as 32 instâncias reais de **High** classificadas como **Low**). Este fenómeno sugere que certas combinações meteorológicas produzem sinais ambíguos para o modelo. Por exemplo, um dia de inverno com céu limpo apresenta radiação solar máxima, mas a curta duração do dia e as temperaturas baixas resultam numa produção global reduzida. Perante picos de radiação, o modelo pode prever um escalão superior, o que demonstra que a realidade energética ultrapassa a simples leitura linear de indicadores isolados.

2.3.2. Modelação e Avaliação: Regressão

Como complemento à tarefa de classificação, o projeto explorou a vertente de regressão. O objetivo desta análise extra incide sobre a previsão exata e contínua da carga injetada na rede (*Distribution Network* (kWh)). A Figura 9 ilustra o fluxo de trabalho desenhado para a modelação e avaliação numérica.




Figura 9: Fluxo de modelação e avaliação para regressão (*DataSet* Produção).

Adaptação do Pré-Processamento e Prevenção de Fuga de Informação: A preparação dos dados partilhou a estrutura base da classificação, com adaptações críticas

para evitar o fenómeno de **Data Leakage**. O nó **Column Filter** isolou o alvo numérico através da exclusão da variável categórica *Productions* e, fundamentalmente, de todas as restantes parcelas de energia (como **Hydro**, **Solar**, entre outras). Uma vez que a soma destas parcelas resulta no valor total da rede, a sua inclusão permitiria ao modelo aprender uma relação aritmética trivial, anulando o seu propósito preditivo. Assim, assegurou-se que as previsões derivam exclusivamente de indicadores meteorológicos.

Para a estabilização da matriz, o fluxo integrou um **Low Variance Filter** e a normalização através de **Decimal Scaling**. Esta técnica revelou-se superior a normalizações mais agressivas, pois preserva a integridade da distribuição original enquanto escala os dados para o processamento. Para garantir a interpretabilidade imediata, a variável alvo foi mantida na escala original, permitindo que as métricas de erro reflitam desvios físicos diretos.

Otimização de Hiperparâmetros e Avaliação de Modelos: A eficácia dos modelos foi aferida através do coeficiente de determinação (R^2) e do erro médio absoluto (MAE). O desenho experimental submeteu três arquiteturas a ciclos de afinação iterativa. A Tabela 8 resume os resultados destas otimizações.

Algoritmo	R^2 Máximo	MAE (kWh)
Gradient Boosted Trees	0,725	102489,90
Random Forest	0,680	117178,85
Simple Regression Tree	0,545	140749,40

Tabela 8: Otimização de hiperparâmetros dos modelos de regressão (*DataSet Produção*).

Análise de Robustez e Conclusões da Regressão: Com base nos resultados, o **Gradient Boosted Trees** foi submetido a uma auditoria de robustez. A Tabela 9 contrasta o desempenho deste modelo sob as estratégias de particionamento estático e cruzado.

Métrica (GBT Regressor)	Validação <i>Hold-out</i>	<i>Cross-Validation</i>
R^2	0,725	0,709
MAE (kWh)	102489,90	103897,94
RMSE (kWh)	141929,52	145176,84

Tabela 9: Validação de robustez do modelo de regressão GBT (*DataSet Produção*).

Os resultados validam a eficácia da arquitetura otimizada, com o R^2 a atingir a marca de 0,725. Este valor indica que os indicadores meteorológicos conseguem explicar 72,5% da variância da carga produzida, um salto qualitativo expressivo face a iterações preliminares. Embora a previsão do valor numérico exato apresente uma complexidade superior à identificação de classes (devido à volatilidade inerente do clima), o modelo exibe uma robustez considerável. A diferença observada entre o MAE (em torno dos 102 mil kWh) e o RMSE (cerca de 142 mil kWh) sinaliza que o algoritmo penaliza e sofre com alguns eventos extremos atípicos. No entanto, este nível de precisão consolida a

regressão como uma ferramenta quantitativa valiosa e fiável para o planeamento diário e alocação de reservas da infraestrutura.

2.4. Balanço Crítico e Conclusões Técnicas

O desenvolvimento dos modelos preditivos sobre o ***DataSet Par*** permitiu extrair conclusões de elevado valor prático sobre a dinâmica entre a meteorologia e a produção energética. A abordagem dupla, dividida em classificação e regressão, revelou as capacidades reais dos algoritmos de aprendizagem automática na resolução de problemas complexos de gestão de rede.

Interpretação Prática da Classificação: Na vertente de classificação, o algoritmo ***Gradient Boosted Trees*** consolidou-se como a arquitetura mais robusta, ao alcançar uma exatidão (***Accuracy***) de 87,81%. Na prática, isto significa que o algoritmo prevê corretamente o escalão exato de produção em quase nove de cada dez ocorrências meteorológicas. Esta elevada fiabilidade permite aos gestores da infraestrutura preparar reservas de emergência ou planear o armazenamento de excedentes com grande margem de segurança, com base exclusivamente nas previsões atmosféricas.

Interpretação Prática da Regressão: Por outro lado, a regressão assumiu o desafio de estimar o volume de produção contínua em unidades físicas exatas (kWh). O modelo otimizado alcançou um R^2 de 0,725, o que atesta que as condições meteorológicas explicam 72,5% da variação total da energia gerada. A análise revelou um MAE em torno dos 102 mil kWh e um RMSE de aproximadamente 145 mil kWh. Na rotina diária, os desvios aproximam-se do MAE, contudo, perante fenómenos climáticos extremos, os erros pontuais elevam o RMSE. Por conseguinte, este último atua como uma margem de segurança essencial: estabelece a quota de energia extra que o sistema necessita de escoar, armazenar ou compensar via fontes convencionais em caso de desvios meteorológicos atípicos.

Rigor Metodológico e Prevenção de Fugas de Informação: O sucesso destas modelações assentou num pré-processamento estrito. A remoção deliberada de variáveis auxiliares de energia garantiu a imunidade do sistema à fuga de informação (***Data Leakage***), assegurando que o algoritmo não memorizou uma relação aritmética trivial, mas aprendeu genuinamente a influência do clima. Adicionalmente, a análise empírica comprovou que os valores estatisticamente extremos (***outliers***) constituem eventos meteorológicos reais com um peso preditivo inestimável, o que validou a adoção de um pré-processamento conservador.

Em conclusão, a utilização conjunta destes modelos fornece uma solução completa para a gestão da produção energética. A previsão de classes assegura a estabilidade geral da infraestrutura, enquanto a estimativa numérica permite o ajuste preciso da capacidade injetada na rede. Estes algoritmos transformam variáveis climáticas em decisões

operacionais e otimizam a integração sustentável de fontes renováveis com segurança e eficiência.

3. *DataSet* Grupo

3.1. Introdução, Pré-Processamento e Exploração do Domínio

O *dataset* selecionado, Laptop Prices, foi escolhido pela sua elevada densidade de informação não estruturada. A análise preliminar revelou inconsistências no formato dos dados (ex: unidades de medida misturadas com valores numéricos), o que exigiu uma estratégia rigorosa de Feature Engineering.

O objetivo central foi transformar atributos textuais (como *ScreenResolution*, *Cpu* e *Memory*) em variáveis preditoras quantitativas, de forma a permitir a aplicação de algoritmos de aprendizagem supervisionada para a previsão do *Price_euros*.

O conjunto de dados Laptop Prices é composto por 13 atributos distintos, com uma mistura de dados categóricos, numéricos e informações textuais complexas. Esta heterogeneidade, descrita na Tabela 10, motivou a necessidade crítica de Feature Engineering descrita na secção de Tratamento de Dados, com o objetivo de converter formatos não estruturados (como '128GB SSD + 1TB HDD') em variáveis quantitativas tratáveis pelos modelos de aprendizagem.

Segue-se a tabela dos atributos do *dataset* Laptop Prices:

Atributo	Tipo	Descrição
laptop_ID	ID	Identificador único da linha de registo.
Company	Categórico	Marca ou fabricante do portátil.
Product	Categórico	Nome do modelo ou gama.
TypeName	Categórico	Tipo de categoria (<i>Ultrabook</i> , <i>Gaming</i> , <i>Notebook</i> , etc.).
Inches	Numérico	Dimensão do ecrã em polegadas.
ScreenResolution	Texto	Resolução do ecrã e tecnologias de painel.
Cpu	Texto	Marca, modelo e velocidade do processador.
Ram	Texto/Num	Capacidade de memória RAM (GB).
Memory	Texto	Tipo e capacidade de armazenamento (SSD/HDD).
Gpu	Texto	Modelo da unidade de processamento gráfico.
OpSys	Categórico	Sistema operativo instalado.
Weight	Texto/Num	Peso do equipamento (kg).
Price_euros	Numérico	Preço de venda (Alvo: Regressão).

Tabela 10: Dicionário de atributos do conjunto de dados (*DataSet Laptop Prices*).

3.2. Visualização Gráfica e Análise Exploratória

Antes de proceder à transformação matemática da matriz, a exploração visual dos dados permitiu identificar padrões e problemas estruturais que ditaram as decisões de pré-processamento.




Figura 10: Distribuição de preços por fabricante.

O **Box Plot** ilustra a variabilidade de preços segmentada por fabricante. Observa-se que marcas como a Apple e Razer apresentam um preço mediano superior com menor dispersão, o que reflete um posicionamento de mercado de gama alta. Em contraste, fabricantes como Lenovo, Dell ou HP exibem uma vasta gama de preços com **outliers** significativos, o que evidencia uma estratégia de mercado abrangente que serve desde o segmento de entrada até às estações de trabalho de alto desempenho.

Heatmap




Figura 11: *HeatMap* entre atributos numéricos e preço.

O *HeatMap* permite identificar os **drivers** de custo no mercado de portáteis. Confirma-se uma correlação forte e positiva entre a capacidade de Ram e o Price_euros, o que valida a sua importância como preditor primário. Observa-se também a presença de multicolinearidade entre variáveis como a resolução do ecrã e a performance da GPU, o que justifica a aplicação de técnicas de seleção de atributos para evitar a redundância de informação durante o treino dos modelos.




Figura 12: Distribuição de frequência dos preços dos portáteis.

O **histograma** de Price_euros apresenta uma concentração acentuada das frequências nas faixas de preço mais baixas (lado esquerdo), o que caracteriza uma assimetria positiva. Este padrão visual demonstra que o mercado é composto maioritariamente por dispositivos de gama de entrada e média, enquanto a “cauda” que se estende para a direita representa a oferta limitada de portáteis de luxo ou de alta performance. Esta configuração da distribuição justifica a aplicação de técnicas de normalização ou transformação logarítmica, de forma a comprimir esta assimetria e mitigar o impacto dos valores extremos (*outliers* de preço elevado) durante o treino dos modelos de regressão.

Pie Chart




Figura 13: Composição percentual das categorias de portáteis (TypeName).

O ***Pie Chart*** evidencia um desequilíbrio entre as classes (TypeName), com a categoria Notebook a dominar a maior quota de mercado. Esta disparidade reforça a necessidade de aplicar ***Stratified Sampling*** durante o particionamento dos dados, de modo a garantir que as classes minoritárias (como Workstation ou Gaming) estejam devidamente representadas no conjunto de teste e para evitar que o modelo subestime estas categorias menos frequentes.




Figura 14: Dispersão da memória RAM em função do preço de venda.

O **Scatter Plot** entre a memória Ram e o Price_euros demonstra uma relação linear positiva com patamares de preço definidos. Nota-se que o aumento de RAM impacta o preço de forma escalonada, o que confirma que a memória é um dos fatores críticos na precificação. A dispersão observada nos pontos sugere que, embora a RAM seja um preditor forte, o preço final é também influenciado por outras variáveis latentes, como a geração do processador ou a marca do equipamento.

3.3. Tratamento de Dados

Para processar a complexidade revelada na exploração visual, a estratégia adotada passou por organizar o fluxo de trabalho em oito metanós sequenciais. A figura seguinte ilustra a arquitetura global, onde cada metanó cumpre um objetivo específico de transformação ou análise.




Figura 15: Fluxo global de tratamento, modelação e avaliação.

O tratamento de dados foi executado através de um fluxo modular composto pelos seis primeiros metanós, para garantir a conversão de um *dataset* não estruturado numa matriz numérica pronta para modelação.

Metanó 1 (Ingestão):

- Importação via *CSV Reader* e remoção da coluna `laptop_ID`, por ser irrelevante para a predição.

Metanó 2 (Limpeza de Unidades):

- Aplicação de *Column Expressions* para remoção de unidades de medida (“GB”, “Kg”) e *String to Number* para a conversão de `Ram` e `Weight` para tipos numéricos.

Metanó 3 (Extração de Hardware):

- Separação da coluna `Cpu` em marca e frequência (via *String Splitter*), limpeza de sufixos (“GHz”) e normalização de strings para a coluna `ScreenResolution`.

Metanó 4 (Engenharia de Atributos):

- Fase crítica de enriquecimento de dados:
 - ▶ **Categorização:** Criação de variáveis categóricas padronizadas para `OpSys` (*Windows, Mac, Linux/NoOS*), `CPU` (*Intel/AMD*) e `GPU` (*Nvidia/AMD/Intel*).
 - ▶ **Variáveis Binárias:** Extração de atributos booleanos para `Touchscreen` e `IPS` (via codificação 1/0).
 - ▶ **Extração de Armazenamento:** Aplicação de expressões regulares para isolar capacidades (GB) de diferentes tecnologias (*Flash, Hybrid, HDD, SSD*).
 - ▶ **Limpeza de Nome:** Padronização do nome dos modelos `Product` (remoção de parênteses e caracteres especiais).

A lógica implementada neste metanó, através de múltiplas estruturas condicionais e *Regex*, permitiu transformar variáveis de texto complexas em indicadores estruturados. A extração de capacidades de armazenamento e a categorização hierárquica do `CPU` e `GPU` foram vitais para que os modelos de aprendizagem pudessem captar o impacto de cada componente específico no valor final do portátil.

Metanó 5 (Métricas Avançadas):

- Cálculo da resolução total (*pixels*) via decomposição da `ScreenResolution` e refinamento da coluna `CPU` para detalhar família e geração, com a consequente remoção de colunas redundantes.

Metanó 6 (Controlo de Qualidade):

- Imputação de valores em falta, aplicação de *Capping* via *Numeric Outliers* ($k = 1.5$), cálculo de novas métricas (`Log_Price`, `PPI`) e uso do *Domain Calculator* para validar os domínios numéricos e categóricos finais.

3.4. Modelação e Avaliação

Para a tarefa de Regressão (Metanó 8), o *workflow* foi particionado numa proporção de 80% para treino e 20% para teste, para assegurar a integridade da avaliação. Após a normalização dos dados (*Min-Max Normalizer*), utilizou-se o *Random Forest Regression Learner* como base. A otimização dos hiperparâmetros (*numModels* e *maxDepth*) foi realizada via *Parameter Optimization Loop*, o que permitiu encontrar o equilíbrio entre a complexidade do modelo e o erro quadrático médio (RMSE).

Exp ID	Descrição da Variação	Justificação Técnica	R ²
1	<i>Baseline: Linear Regression</i>	Ponto de comparação base	0.65
2	<i>Champion: Random Forest</i>	Modelos não lineares	0.89
3	<i>Sem Feature Extraction</i>	Impacto da limpeza	0.45
4	<i>Brand Agnostic</i>	Análise do peso da marca	0.82

A análise comparativa permite concluir que a performance do modelo é fortemente dependente da qualidade da engenharia de características. A remoção da coluna *Company* (*Brand Agnostic*) provou que o mercado de portáteis atribui um valor acrescentado à marca que supera o hardware bruto, o que valida a importância da limpeza de dados na captura de nuances de mercado.




Figura 16: Fluxo *Regression Tree + Opt.*

Utilizou-se uma Árvore de Decisão como *benchmark* inicial. Como modelo de “caixa branca”, permite interpretar quais as variáveis que mais contribuem para a decisão (como a RAM enquanto critério de divisão primário). A otimização procurou a profundidade máxima (*maxDepth*) capaz de equilibrar a precisão sem incorrer em *overfitting* imediato.




Figura 17: Fluxo *Random Forest + Opt.*

O objetivo desta abordagem consistiu em reduzir a variância do modelo. Enquanto a árvore única é sensível ao ruído dos dados, a *Random Forest* estabiliza a predição através da agregação (*bagging*) de múltiplas árvores. A otimização focou-se no número de árvores geradas (*numModels*) e na aleatoriedade dos atributos para garantir robustez estatística.




Figura 18: Fluxo *GBT Regression + Opt.*

A arquitetura GBT foi incluída para minimizar o viés (*bias*) do modelo. Ao contrário da *Random Forest*, o GBT constrói árvores de forma sequencial, com uma aprendizagem baseada nos erros (resíduos) das iterações anteriores. Como é um modelo mais complexo e propenso a *overfitting*, a otimização de parâmetros como *learningRate* e *maxDepth* foi determinante para encontrar o ponto de convergência ótima.




Figura 19: Fluxo Rede Neural *Keras*.

A inclusão de uma Rede Neuronal (*Keras*) visou testar a capacidade de generalização de um modelo de *Deep Learning* perante relações não-lineares complexas. Contudo, o resultado obtido (R^2 negativo) revelou uma incapacidade do modelo em convergir para um padrão preditivo útil, com um desempenho inferior ao de uma média simples. Este fenómeno ilustra a desadequação desta arquitetura para a dimensão atual do *dataset*; a elevada complexidade da rede face ao número reduzido de instâncias induziu uma falha na aprendizagem (*underfitting*), o que reforça a necessidade de adequar o algoritmo ao volume de dados.




Figura 20: Fluxo *Ensemble RF + GBT*.

A estratégia de Ensemble baseou-se na diversidade dos modelos: o Random Forest (eficiente na redução da variância) e o Gradient Boosting (focado na redução do viés). Ao combinar ambos, é possível mitigar os erros sistemáticos de cada abordagem individual, com o resultado de uma generalização superior. Esta constitui a estratégia de máxima robustez do projeto.

Modelo	Estratégia de Aprendizagem	Vantagem Principal	R ² (Ajustado)
<i>Regression Tree</i>	<i>Baseline</i>	Alta Interpretabilidade	0.780
<i>Random Forest</i>	<i>Bagging</i>	Estabilidade/Robustez	0.852
<i>GBT</i>	<i>Boosting</i>	Redução de Erro/Precisão	0.841
<i>Keras</i>	<i>Deep Learning</i>	Captura de Relações Complexas	-2.956
<i>Ensemble</i>	<i>Stacking</i>	Otimização da Generalização	0.861

A análise comparativa permite concluir que a performance preditiva não é linearmente proporcional à complexidade algorítmica. Embora o *GBT* tenha demonstrado uma precisão elevada, foi o modelo de *Ensemble* que obteve a melhor métrica de teste (R² de 0.861). O desempenho negativo da Rede Neuronal funciona como uma demonstração analítica da importância da escolha do modelo em função da natureza do *dataset*, o que confirma que, para este problema de regressão, a combinação de paradigmas (*Bagging* + *Boosting*) supera a aplicação de modelos profundos.

3.5. Balanço Crítico e Conclusões Técnicas

A conclusão deste projeto permite validar que a eficácia de um sistema de aprendizagem automática reside na simbiose entre a qualidade dos dados e a estratégia de modelação. O desenvolvimento deste fluxo para o *Dataset Laptop Prices* gerou as seguintes observações técnicas:

- **A Centralidade da *Feature Engineering*:** A superioridade do modelo *Ensemble* não foi um acaso, mas o resultado direto da transformação rigorosa de dados não estruturados em variáveis numéricas. A fase de limpeza de dados provou ser a base do desempenho; sem esta, os modelos de *baseline* mal conseguiam captar tendências básicas, o que confirma o princípio de que a qualidade da predição é limitada pela pureza da informação de entrada.
- **O Princípio da Parcimónia:** A falha técnica da Rede Neuronal (*Keras*) evidenciou que o aumento de complexidade arquitetural sem o devido volume de dados conduz invariavelmente ao *underfitting* ou à instabilidade. O sucesso do modelo de *Ensemble* reitera que, para problemas tabulares de escala moderada, os algoritmos baseados em árvores continuam a ser a ferramenta mais eficaz para equilibrar a precisão e a robustez contra o ruído.

- **A Natureza Subjetiva do Preço:** Apesar da elevada precisão alcançada, o modelo ainda enfrenta dificuldades em prever as extremidades da distribuição de preços. Isto demonstra que o preço final não é uma função estrita das especificações de hardware; variáveis latentes, como o prestígio da marca, o design industrial ou a disponibilidade sazonal, introduzem um ruído que o modelo puramente técnico não consegue quantificar na totalidade.

Considerações para Trabalhos Futuros:

O desenvolvimento deste trabalho abre portas para melhorias futuras. A integração de seleção de atributos avançada poderia simplificar o modelo através da redução da dimensionalidade sem perda de precisão. Adicionalmente, a exploração de dados externos (como a cotação de mercado ou o histórico de lançamentos) poderia elevar a variância explicada, com o intuito de reduzir o resíduo estatístico associado a fatores externos não técnicos.

Em suma, a modelação de preços provou ser um exercício rigoroso de otimização multivariável. A estratégia adotada, que combinou a extração manual de características com modelos robustos, revelou-se a solução mais equilibrada para a extração de conhecimento neste domínio, o que consolida as competências de avaliação exigidas.

4. Conclusão

O presente projeto permitiu consolidar o ciclo de vida completo de sistemas preditivos, desde a ingestão de dados brutos até à avaliação estruturada de modelos. A abordagem dupla, aplicada à produção energética (*DataSet* Par) e à análise do mercado de hardware (*DataSet* Grupo), demonstrou que os princípios metodológicos da ciência de dados permanecem universais, independentemente do domínio.

A Prevalência do Pré-Processamento: Através da exploração de ambos os conjuntos de dados, verificou-se que a qualidade da matriz de dados prevalece sobre a complexidade algorítmica. Em ambos os casos de estudo, o sucesso preditivo dependeu do rigor analítico aplicado na fase de preparação. Etapas como a limpeza estrutural, a preservação de *outliers* como eventos físicos reais e a transformação matemática de atributos (*Feature Engineering*) revelaram-se críticas para assegurar a capacidade de generalização dos algoritmos.

O Equilíbrio entre Complexidade e Desempenho: A experiência prática validou a eficácia das arquiteturas de *Ensemble* (*Random Forest* e *Gradient Boosted Trees*). Estes algoritmos ofereceram o equilíbrio técnico necessário, com capacidade para mapear relações não-lineares complexas em simultâneo com a preservação de níveis adequados de interpretabilidade. Em contrapartida, a aplicação de redes neuronais profundas (Keras) confirmou o princípio da parcimónia: o aumento da complexidade arquitetural sem o volume de dados adequado resulta em instabilidade e diminuição do poder preditivo.

Rigor Metodológico e Fiabilidade: A utilização de amostragem estratificada (*Stratified Sampling*) e a prevenção estrita de fuga de informação (*Data Leakage*) constituíram princípios transversais a todo o processo. Estas práticas operacionais, aliadas à validação cruzada (*Cross-Validation*), atestaram a ausência de sobreajuste (*overfitting*) e confirmaram a resiliência das soluções. Este escrutínio estatístico comprova a aptidão técnica dos modelos para integração em cenários práticos de suporte à decisão.

Considerações Finais: Em suma, a execução deste trabalho atesta que a inteligência computacional permite transformar variáveis brutas num ativo operacional. A avaliação sistemática do comportamento de diferentes algoritmos consolidou competências técnicas e analíticas fulcrais na área de Engenharia Informática, essenciais para o desenvolvimento de arquiteturas de *Machine Learning* sustentadas em dados reais.

5. Referências Bibliográficas

- [1] Universidade do Minho, «Slides da UC - Aprendizagem e Decisão Inteligentes (2025/2026)», Universidade do Minho.
- [2] «KNIME Community Hub». [Em linha]. Disponível em: <https://hub.knime.com/>
- [3] Tom Mitchell, *Machine Learning*. McGraw Hill.